

Лабораторная работа №6

Сегментация текста

Вариант 7: иврит.

Постановка задачи

Используя алфавит из предыдущей лабораторной работы, необходимо подготовить строку текста, построить её горизонтальный и вертикальный профили, выполнить сегментацию символов и сохранить координаты ограничивающих прямоугольников.

Исходные данные

- алфавит: иврит;
- шрифт: Arial;
- кегль: 96;
- используемая фраза: «Я люблю тебя» на иврите;
- формат входного изображения: монохромный BMP.


Алгоритм сегментации

- строится профиль по строкам для выделения текстовой строки;
- в пределах найденной строки строится профиль по столбцам;
- столбцы с числом чёрных пикселей не более 1 считаются разрывами профиля;
- по непрерывным участкам профиля определяются границы символов;
- для выбранного алфавита порядок сегментов фиксируется справа налево.

Исходная строка и профили

אני אחיה בלול


Горизонтальный профиль



Вертикальный профиль



Результат сегментации



Координаты символов

index	symbol_name	symbol_char	left	top	right	bottom
1	alef	א	625	23	670	72
2	nun	נ	577	23	600	73
3	yod	י	543	35	552	60
4	alef	א	453	23	498	72
5	vav	ו	419	23	428	72
6	he	ה	351	23	394	73
7	bet	ב	279	23	326	73
8	alef	א	189	24	234	73
9	vav	ו	155	24	164	73
10	tav	ת	78	23	130	73
11	final_kaf	ך	14	14	53	83

Вырезанные символы

Вырезанные символы строки

01 alef	02 nun	03 yod	04 alef	05 vav	06 he
07 bet	08 alef	09 vav	10 tav	11 final_kaf	

Итог работы алгоритма

Алгоритм выделил 11 сегментов, что соответствует числу символов во входной строке без учёта пробелов.

Профили алфавита

Эталонные символы иврита

 א alef	 ב bet	 ג gimel	 ד dalet	 ה he	 ו vav
 ז zayin	 ח het	 ט tet	 י yod	 כ kaf	 ל lamed
 מ mem	 נ nun	 ס samekh	 ע ayin	 פ pe	 צ tsadi
 ק qof	 ר resh	 ש shin	 ת tav	 ך final_kaf	 ם final_mem
 ן final_nun	 ף final_pe	 ץ final_tsadi			

Вывод

В ходе выполнения лабораторной работы построены горизонтальный и вертикальный профили текстовой строки, реализован алгоритм сегментации символов по профилям и получен массив координат ограничивающих прямоугольников. Дополнительно сформированы профили символов выбранного алфавита, что позволяет использовать их в последующих задачах анализа и распознавания текста.