

Лабораторная работа №7

Классификация на основе признаков

Вариант 7: иврит.

Постановка задачи

Необходимо распознать символы сегментированной строки на основе признаков, рассчитанных в предыдущих лабораторных работах. Для каждого сегмента строится список гипотез по всем символам алфавита, после чего выбирается наиболее правдоподобная гипотеза.

Используемые признаки

- нормированная масса символа;
- нормированные координаты центра тяжести;
- нормированные моменты инерции по X и Y.

Мера близости

Расстояние между символами вычисляется как евклидово расстояние в пространстве признаков:
 $d = \sqrt{\sum (f_i - g_i)^2}$.


Мера близости определяется формулой $S = 1 / (1 + d)$. При $d = 0$ близость равна 1.

Параметры эксперимента

- эталонный шрифт: Arial, 96 пунктов;
- базовая распознаваемая строка: Arial, 96 пунктов;
- экспериментальная строка: Arial, 106 пунктов;
- фраза: «Я люблю тебя» на иврите.

Эталонный набор

Эталонные символы иврита

 א alef	 ב bet	 ג gimel	 ד dalet	 ה he	 ו vav
 ז zayin	 ח het	 ט tet	 י yod	 כ kaf	 ל lamed
 מ mem	 נ nun	 ס samekh	 ע ayin	 פ pe	 צ tsadi
 ק qof	 ר resh	 ש shin	 ת tav	 ך final_kaf	 ם final_mem
 ן final_nun	 ף final_pe	 ץ final_tsadi			


Файл признаков

output/template_features.csv содержит нормированные признаки для всех 27 символов.


Базовая строка

Распознавание при том же размере шрифта

אני אהב אותך



Сегменты базовой строки



Распознанная строка: אני אהב אותך

Количество ошибок: 0; точность: 100.00%.

Лучшие гипотезы

Базовый случай


base: лучшие гипотезы

```
01: א (alef) 1.0000 | ש (shin) 0.9836 | ט (samekh) 0.9788
02: נ (nun) 1.0000 | צ (tsadi) 0.9650 | ג (gimel) 0.9618
03: י (yod) 1.0000 | ו (ayin) 0.9619 | ו (vav) 0.9473
04: א (alef) 1.0000 | ש (shin) 0.9836 | ט (samekh) 0.9788
05: ו (vav) 1.0000 | ך (final_nun) 0.9785 | א (alef) 0.9623
06: ה (he) 1.0000 | ת (tav) 0.9697 | ו (ayin) 0.9625
07: ב (bet) 1.0000 | ג (gimel) 0.9685 | צ (tsadi) 0.9552
08: א (alef) 1.0000 | ש (shin) 0.9836 | ט (samekh) 0.9788
09: ו (vav) 1.0000 | ך (final_nun) 0.9785 | א (alef) 0.9623
10: ת (tav) 1.0000 | ה (he) 0.9697 | פ (pe) 0.9674
11: ך (final_kaf) 1.0000 | ר (resh) 0.9673 | ד (dalet) 0.9123
```



Эксперимент

Распознавание строки шрифтом 106 пунктов

אני אוהב אותך



Сегменты экспериментальной строки



Распознанная строка: ׀תוא בהוא ינא

Количество ошибок: 0; точность: 100.00%.

Лучшие гипотезы

Экспериментальный случай

experiment: лучшие гипотезы

01: א (alef) 0.9879 | ש (shin) 0.9878 | ט (samekh) 0.9833
02: נ (nun) 0.9817 | צ (tsadi) 0.9641 | ג (gimel) 0.9496
03: י (yod) 0.9931 | ו (ayin) 0.9639 | ו (vav) 0.9536
04: א (alef) 0.9879 | ש (shin) 0.9878 | ט (samekh) 0.9833
05: ו (vav) 0.9931 | ך (final_nun) 0.9851 | פ (pe) 0.9610
06: ה (he) 0.9862 | ת (tav) 0.9777 | ט (tet) 0.9606
07: ב (bet) 0.9814 | ג (gimel) 0.9648 | צ (tsadi) 0.9639
08: א (alef) 0.9879 | ש (shin) 0.9878 | ט (samekh) 0.9833
09: ו (vav) 0.9931 | ך (final_nun) 0.9851 | פ (pe) 0.9610
10: ת (tav) 0.9903 | פ (pe) 0.9668 | ה (he) 0.9632
11: ך (final_kaf) 0.9812 | ר (resh) 0.9587 | ד (dalet) 0.9054

Сравнение результатов

Сводная таблица

case		font_size		predicted		errors		accuracy
base		96		רתוא בהוא ינא		0		100.00
experiment		106		רתוא בהוא ינא		0		100.00

Вывод

Для варианта 7 реализована классификация символов иврита на основе нормированных признаков: массы, координат центра тяжести и моментов инерции. В базовом случае и в эксперименте с увеличением кегля до 106 пунктов строка была распознана без ошибок. Это показывает, что выбранные нормированные признаки сохраняют устойчивость к умеренному изменению размера шрифта.